

Nivell 1: Entorn i Ingesta Híbrida (Code-First)

Exercici 1: Arquitectura de Dades (Lògica vs. Física)


🧩 Tasques:

Implementareu físicament l'arquitectura lògica creant tres Datasets dins d'un mateix projecte per centralitzar la facturació i els permisos.

👉 Crea un **Nou Projecte** a Google Cloud anomenat:

sprint3-analytics-[el-teu-nom].

Ho pots crear per la UI, però si ho fas per Consola (gcloud CLI) té un plus.




En la consola de Google Cloud, accedim a New Project, y rellenamos los campos Project name con el nombre del proyecto que queremos darle. Para esta práctica, elegiremos 'No organisation' como Parent resource. Finalmente crearemos el proyecto dando al botón 'Create'.


Per demostrar el teu domini total de la plataforma, crearàs cadascun dels datasets utilitzant un mètode diferent:

» **Dataset Físic** sprint3_bronze → Capa Lògica Bronze (Dades Crudes)

- Funció: Dades crues tal com arriben de la font.
- Mètode: Utilitza la **Interfície Gràfica (UI)** de BigQuery (fent clics).



Accedemos al proyecto que acabamos de crear. De ahí vamos a la pestaña de Studio en el panel de la izquierda. En el Explorer, buscamos el nombre del proyecto, y pinchamos en los 3 puntos verticales para que se despliegue un menú, dónde encontraremos la opción de 'Create dataset'.




Se abrirá un panel a la derecha, en el que rellenaremos Data set ID con el nombre que le queramos dar al dataset ('sprint3_bronze' en nuestro caso). Para este proyecto, especificaremos la Data location 'EU'. Es muy importante que todos los datasets estén en la misma región, ya que si no no podrán comunicarse entre ellos correctamente. Finalmente pinchamos en el botón Create data set.

Comprobaremos que los datasets han sido creados satisfactoriamente al final del apartado.

» Dataset Físic sprint3_silver → Capa Lògica Silver (Dades Netes)


- Funció: Dades netes, tipades i deduplicades.
- Mètode: Utilitza codi SQL (CREATE SCHEMA).




Para crear un dataset mediante consultas SQL, abrimos una nueva pestaña de consultas desde el proyecto, e introducimos el código CREATE SCHEMA IF NOT EXISTS para crear un nuevo dataset (SCHEMA) si no existe, con el nombre como ubicación del mismo. Como opciones, solo establecemos que la localización sea 'EU'.

» Dataset Físic sprint3_gold → Capa Lògica Gold (Dades de Negoci)

- Funció: Dades agregades llestes per a informes i panells de control (dashboards).
- Mètode: Utilitza Cloud Shell (Línia d'ordres bq).



Para crear un dataset a través de la consola, primero abrimos Cloud Shell (arriba a la derecha), e introducimos el comando bq que se ve por pantalla para crear el tercer dataset sprint3_gold en la Region 'EU'.



Desde el explorador, comprobaremos que todos los datasets han sido creados satisfactoriamente en la región 'EU'.


Exercici 2: Ingesta en Capa Bronze (Connexió DDL)

🧩 Tasca:

Escriu i executa les sentències `CREATE EXTERNAL TABLE` per connectar els següents fitxers al *dataset* **sprint3_bronze**. Para molta atenció a les "Notes Tècniques", ja que no tots els arxius tenen el mateix format.

👉 Entrega:

El codi SQL utilitzat per a `transactions_raw` i una captura de pantalla amb les 5 taules creades.



```
1 CREATE EXTERNAL TABLE `sprint3-analytics-jordi-m.sprint3_bronze.transactions_raw`
2 (
3   id STRING,
4   card_id STRING,
5   business_id STRING,
6   timestamp STRING,
7   amount STRING,
8   declined STRING,
9   product_ids STRING,
10  user_id STRING,
11  lat STRING,
12  longitude STRING
13 )
14 OPTIONS (
15   format = 'CSV',
16   uris = ['gs://bootcamp-data-analytics-public/ERP/transactions.csv'],
17   field_delimiter = ';',
18   skip_leading_rows = 1);
```

Query completed

Query results

Job information Results Execution details Execution graph

This statement created a new table named transactions_raw. Go to table

Crearem la taula externa 'transactions_raw' dentro del dataset 'sprint3_bronze'. Basado en la estructura del CSV le pasamos los nombres de las columnas y todas las introducimos como STRING. Este aspecto es muy importante para respetar la arquitectura Medallion y que no se pierda información.

Como opciones, introducimos el formato del archivo (CSV en este caso), la URI desde la cuál bajaremos los datos, le especificaremos que usaremos como delimitador un ';' en lugar de la ',' por defecto debido a la composición de este archivo en particular, y nos saltaremos la primera fila, ya que si no, la primera fila coge lo que deberían ser los nombres de las columnas. Seguiremos el mismo proceso para el resto de tablas, excepto por el hecho de especificar el delimitador.

Explorer + Add data

Search for resources

Home

Starred

Shared with me

Job history

sprint3-analytics-jordi-m

Datasets

Connections

Conversations

Agents

Queries

(Classic) Queries

Notebooks

Data canvases

Data preparations

Pipelines

sprint3-analytics-jordi-m / Datasets / sprint3_bronze

☆ sprint3_bronze

Create table Chat Preview Share Copy Delete Refresh

Overview Details Insights Preview

Tables Graphs Models Routines


Filter Enter property name or value

Table ID	Type	Create time	Expiry time	Label
american_users_raw	Table	5 Jun 2026, 17:53:00 UTC+2	4 Aug 2026, 17:53:00 UTC+2	None
companies_raw	Table	5 Jun 2026, 17:52:44 UTC+2	4 Aug 2026, 17:52:44 UTC+2	None
credit_cards_raw	Table	5 Jun 2026, 17:53:20 UTC+2	4 Aug 2026, 17:53:20 UTC+2	None
european_users_raw	Table	5 Jun 2026, 17:53:10 UTC+2	4 Aug 2026, 17:53:10 UTC+2	None
transactions_raw	Table	5 Jun 2026, 17:49:48 UTC+2	4 Aug 2026, 17:49:48 UTC+2	None


Visualizamos las tablas creadas hasta ahora en el dataset 'sprint3_bronze'.

Exercici 3: Càrrega de Dades Locals (Upload)

Falta el catàleg de **Productes**. Aquesta informació no és al Data Lake, utilitza el fitxer *products.csv* de l'sprint 2.



La tabla 'products' la crearem a partir del CSV que utilitzem en el Sprint 2, así que accedemos a la pestaña 'Create table' dentro del dataset 'sprint3_bronze'. Buscamos y seleccionamos el archivo, y especificamos el destino, dónde queremos que se suba. Para esta opción, utilizaremos el 'Auto-detect' para que detecte automáticamente qué tipo es cada columna del archivo CSV. Permitir que detecte automáticamente el esquema no es una buena práctica durante la capa 'bronze', ya que como veremos en la próxima imagen, puede asignar tipos de datos que no son los más apropiados.



Como podemos observar, a la columna 'price' le asigna el tipo FLOAT, y esto podría arrastrar errores a la hora de convertir valores decimales. Para valores monetarios es mejor convertirlos a NUMERIC.

Exercici 4: Arquitectura i Rendiment. Materialització de Dades (Assistit per IA)

Escenari:

Les consultes sobre el Data Lake van lentes. Has de demostrar al teu mànager la diferència de rendiment entre treballar amb fitxers externs i treballar amb taules natives de BigQuery.

a) Materialització de Dades (Assistit per IA)

Tasca:

Crea una nova taula anomenada `sprint3_bronze.transactions_raw_native` que sigui una còpia exacta de la teva taula externa `transactions_raw`.

Requisit de "AI-Pair Programming":

No escriguis el codi SQL manualment. Utilitza l'Assistent d'IA (Gemini) integrat a BigQuery (o el xat lateral) per generar la sentència.

Entrega:

Una captura de pantalla on es vegi:

- » El prompt que vas escriure a la IA.
- » El codi SQL que la IA va generar.
- » El resultat de l'execució ("This statement created a new table...").

The screenshot shows the Google Cloud BigQuery interface. On the left, a SQL query is written in a text editor:

```
1 CREATE OR REPLACE TABLE `sprint3-analytics-jordi-m.sprint3_bronze.transactions_raw_native` AS
2 SELECT
3 *
4 FROM
5 `sprint3-analytics-jordi-m.sprint3_bronze.transactions_raw`;
```

Below the query editor, the 'Query results' section shows the execution details:

Job ID	sprint3-analytics-jordi-m:EU.bqjob_f1bc578_19e987d2632 (See performance details)
User	@gmail.com
Location	EU
Creation time	5 Jun 2026, 17:53:20 UTC+2
Start time	5 Jun 2026, 17:53:20 UTC+2
End time	5 Jun 2026, 17:53:20 UTC+2
Duration	0 sec
Bytes processed	0 B
Bytes billed	0 B
Slot milliseconds	0
Job priority	INTERACTIVE
Use legacy SQL	false
Destination table	sprint3-analytics-jordi-m.sprint3_bronze.transactions_raw_native

On the right, the 'Cloud Assist' sidebar shows a prompt and the generated SQL query:

Write a SQL query to create a new table called transactions_raw_native in the sprint3_bronze dataset in the project sprint3-analytics-jordi-m. It should contain all data from the transactions_raw table in the same dataset. Please use CREATE OR REPLACE TABLE so I don't get errors if I run it more than once.

To create the new table containing all data from the existing one, you can use the following SQL query in BigQuery:

```
CREATE OR REPLACE TABLE `sprint3-analytics-jordi-m.sprint3_bronze.transactions_raw_native` AS
SELECT *
FROM `sprint3-analytics-jordi-m.sprint3_bronze.transactions_raw`;
```

Below the query, it says: 'Generated code may be subject to license restrictions not shown here. Use code with care. Learn more'. It also states: 'This query uses the CREATE OR REPLACE TABLE statement as requested, which ensures the table is updated if it already exists without throwing an error.'

Introducimos el prompt especificando lo que queremos, cómo lo queremos, y dónde. También aclaramos que tiene que ser una copia de 'transactions_raw', y que utilice CREATE OR REPLACE TABLE para evitar errores. Revisando el código que nos devuelve y revisando la documentación, el código es válido porque cogerá todo de la tabla 'transactions_raw' como le especificamos, y con ello creará (o sustituirá en caso de que ya exista) una tabla 'transactions_raw_native'.

The screenshot shows the Google Cloud BigQuery interface. On the left, the 'Explorer' sidebar shows the 'sprint3-analytics-jordi-m' dataset. In the main area, the 'sprint3_bronze' dataset is selected, and the 'Tables' tab is active. A list of tables is shown:

Table ID	Type	Create time	Expiry time	Label
american_users_raw	Table	5 Jun 2026, 17:53:00 UTC+2	4 Aug 2026, 17:53:00 UTC+2	None
companies_raw	Table	5 Jun 2026, 17:52:44 UTC+2	4 Aug 2026, 17:52:44 UTC+2	None
credit_cards_raw	Table	5 Jun 2026, 17:53:20 UTC+2	4 Aug 2026, 17:53:20 UTC+2	None
europaean_users_raw	Table	5 Jun 2026, 17:53:10 UTC+2	4 Aug 2026, 17:53:10 UTC+2	None
products_raw	Table	5 Jun 2026, 18:06:17 UTC+2	4 Aug 2026, 18:06:17 UTC+2	None
transactions_raw	Table	5 Jun 2026, 17:49:48 UTC+2	4 Aug 2026, 17:49:48 UTC+2	None
transactions_raw_native	Table	5 Jun 2026, 18:20:31 UTC+2	4 Aug 2026, 18:20:31 UTC+2	None

The 'transactions_raw' and 'transactions_raw_native' tables are highlighted with a red box.

La tabla se creó satisfactoriamente y la vemos junto a las demás, pese a las diferencias que hay entre ambas y veremos a continuación.

b) Auditoria de Costos

🧩 Tasca:

Dissenyar una prova per comparar el cost de llegir una sola columna (ex: id) a la taula externa vs. la taula nativa. Utilitza els Bytes processats i els Bytes facturats per fer la comparació.

- » Quant "pesa" la consulta a `transactions_raw`?
- » Quant "pesa" la mateixa consulta a `transactions_raw_native`?

👉 Entrega:

Captures del validador mostrant la diferència i una conclusió tècnica.

The screenshot shows a query execution interface. At the top, there's a query editor with the following SQL:

```
1 SELECT id
2 FROM 'sprint3-analytics-jordi-m.sprint3-bronze.transactions_raw';
```

Below the editor, a status bar indicates "Query completed". The main section is titled "Query results" and contains a table of job information. The table has columns for Job ID, User, Location, Creation time, Start time, End time, Duration, Bytes processed, Bytes billed, Slot milliseconds, Job priority, Use legacy SQL, and Destination table. The values for the first 11 rows are as follows:

Job ID	User	Location	Creation time	Start time	End time	Duration	Bytes processed	Bytes billed	Slot milliseconds	Job priority	Use legacy SQL	Destination table
sprint3-analytics-jordi-m:EU.bqjob_5321a5fb_19e9899da05	@gmail.com	EU	5 Jun 2026, 18:24:41 UTC+2	5 Jun 2026, 18:24:41 UTC+2	5 Jun 2026, 18:24:43 UTC+2	1 sec	12.61 MB	13 MB	1645	INTERACTIVE	false	Temporary table

The "Bytes processed" and "Bytes billed" rows are highlighted with an orange border.

Seleccionamos 'id' de la tabla 'transactions_raw' y vemos, marcado en naranja que se procesarán 12.61 MB y se facturarán 13 MB.

The screenshot shows the Google Cloud BigQuery interface. At the top, there's a query editor with the following SQL query:

```
1 SELECT id
2 FROM `sprint3-analytics-jordi-m.sprint3_bronze.transactions_raw_native`;
```

Below the query editor, a status bar indicates "Query completed" and "Using on-demand processing quota".

The "Query results" section is expanded, showing a table with job information:

Job ID	sprint3-analytics-jordi-m:EU.bqjob_42e7b4ca_19e989bdf42 (See performance details)
User	@gmail.com
Location	EU
Creation time	5 Jun 2026, 18:26:53 UTC+2
Start time	5 Jun 2026, 18:26:53 UTC+2
End time	5 Jun 2026, 18:26:55 UTC+2
Duration	1 sec
Bytes processed	3.62 MB
Bytes billed	10 MB
Slot milliseconds	740
Job priority	INTERACTIVE
Use legacy SQL	false
Destination table	Temporary table

The "Bytes processed" and "Bytes billed" rows are highlighted with an orange box.

Hacemos la misma consulta en la tabla 'transactions_raw_native' y vemos, marcado en naranja, que se procesarán 3.62 MB y se facturarán 10MB.

La tabla externa lee el fichero CSV, y por eso tiene un coste de proceso y de facturación mayor. Sin embargo, al leer de la tabla nativa, BigQuery usa procesamiento propio, generando un coste menor.

c) El perill del LIMIT

Molts analistes pensen que posar LIMIT 10 redueix el cost de la consulta.

🧩 **Tasca:**

Fes un SELECT * FROM transactions_raw_native LIMIT 10 sobre la taula externa.

✅ **Comprovació:** Mira el "Dry Run". Ha baixat el cost respecte a no posar LIMIT? Explica breument per què això és una trampa per a principiants.

```
1 SELECT *
2 FROM `sprint3-analytics-jordi-mont.sprint3_bronze.transactions_raw_native`;
```

✓ This query will process 13.56 MB when run.

Hacemos un 'Dry Run' seleccionando todo de 'transactions_raw_native', y vemos que el coste de procesamiento sería de 13.56 MB.


```
1 SELECT *
2 FROM `sprint3-analytics-jordi-mont.sprint3_bronze.transactions_raw_native`
3 LIMIT 10;
```

✓ This query will process 13.56 MB when run.

La misma consulta con LIMIT 10 no cambia el coste de procesamiento. LIMIT x no afecta al coste de procesamiento, ya que antes de limitar ha tenido que procesar todo lo demás. Lo que afectará en otras tablas nativas será la cantidad de columnas que utilizemos en el SELECT multiplicado por el número de registros que haya en la tabla.

Exercici 5: Adaptació de Sintaxi (Reporting)

El teu cap vol saber quins van ser els **5 dies amb més ingressos de l'any 2021**.



The screenshot shows a SQL query editor with a query that filters transactions for the year 2021, groups them by date, and orders them by total amount. Below the query, a status bar indicates 'Query completed'. The 'Query results' section shows a table with 5 rows of data.

```
1 SELECT
2   DATE(PARSE_TIMESTAMP('%Y-%m-%d %H:%M:%S', timestamp)) AS fecha,
3   ROUND(SUM(SAFE_CAST(amount AS NUMERIC)), 2) AS total
4 FROM `sprint3-analytics-jordi-m.sprint3_bronze.transactions_raw`
5 WHERE SUBSTR(timestamp, 1, 4) = '2021'
6 AND declined = '0'
7 GROUP BY fecha
8 ORDER BY total DESC
9 LIMIT 5;
```

Query completed

Query results

Job information	Results	Visualisation	JSON	Execution details	Execution graph
Row	fecha	total			
1	2021-10-27	11440.81			
2	2021-01-22	11328.84			
3	2021-02-11	11182.16			
4	2021-04-29	11119.01			
5	2021-03-27	10898.51			


Seleccionamos con la función DATE() la fecha extraída del string en la columna 'timestamp' convirtiéndola previamente a formato TIMESTAMP y la nombramos como fecha. Convertimos a valor NUMERIC (mejor que FLOAT para precios) con un SAFE_CAST() de la columna 'amount', sumando todos los valores agrupados por fecha, y redondeando a dos decimales, y lo nombramos como total. Todos estos valores los tomamos de la tabla 'transactions_raw', filtrando aquellos valores cuyos primeros 4 caracteres de la columna 'timestamp' sean igual a '2021' para quedarnos con aquellas ventas del año 2021, y también cuyo valor en la columna 'declined' sea '0', es decir, falso, ya que no han sido rechazadas. Finalmente agrupamos por la fecha y ordenamos por total de mayor a menor, quedándonos con los 5 primeros resultados. Esta consulta puede tener un alto valor para intentar encontrar patrones de fechas donde más se factura si lo aplicamos también a los diferentes años. De esta manera podemos planear campañas de marketing que beneficien al negocio.

Exercici 6: Consultes Complexes

Necessitem un informe que creui dades.

Tasca:

Llista el nom, país i data de les transaccions realitzades per empreses que van fer operacions entre 100 i 200 euros en alguna d'aquestes dates: 29-04-2015, 20-07-2018 o 13-03-2024.



The screenshot shows a SQL query editor with a query that selects company name, country, date, and total amount from a transactions table, joined with a companies table. The query filters for transactions where the amount is between 100 and 200 and the date is one of the specified dates. Below the query editor, the results are displayed in a table with 10 rows and 5 columns: Row, company_name, country, fecha, and total. The results show transactions for various companies across different countries and dates.

```
1 SELECT
2   c.company_name,
3   c.country,
4   DATE(PARSE_TIMESTAMP('%Y-%m-%d %H:%M:%S', t.timestamp)) AS fecha,
5   SAFE_CAST(t.amount AS NUMERIC) AS total
6 FROM `sprint3-analytics-jordi-m.sprint3-bronze.transactions_raw` AS t
7 JOIN `sprint3-analytics-jordi-m.sprint3-bronze.companies_raw` AS c
8   ON t.business_id = c.company_id
9 WHERE t.declined = '0'
10 AND SAFE_CAST(t.amount AS NUMERIC) BETWEEN 100 AND 200
11 AND DATE(PARSE_TIMESTAMP('%Y-%m-%d %H:%M:%S', t.timestamp)) IN ('2015-04-29', '2018-07-20', '2024-03-13');
```

Query completed

Query results

Job information	Results	Visualisation	JSON	Execution details	Execution graph
Row	company_name	country	fecha	total	
1	At Pedo Corp.	Italy	2018-07-20	115.16	
2	Fusce Corp.	United States	2018-07-20	114.77	
3	Magna Incorporated	New Zealand	2018-07-20	144.16	
4	Et Magnis Ltd	Belgium	2018-07-20	114.44	
5	Ac Libero Inc.	United Kingdom	2024-03-13	172.88	
6	Donec Fringilla PC	France	2015-04-29	187.52	
7	Amet Lorem LLP	Spain	2015-04-29	145.89	
8	Netus Et Malesuada Ltd	Netherlands	2018-07-20	183.64	
9	Ac Libero Inc.	United Kingdom	2015-04-29	124.04	
10	Justo Eu Arcu Ltd	Italy	2018-07-20	136.6	

Results per page: 50 1 - 19 of 19

Extraemos la fecha y el total de manera similar a como lo hicimos en la consulta anterior, y extraemos el nombre de la compañía y el país de la misma a través de un JOIN con la tabla 'companies'. Aplicamos filtros para que sólo nos salgan las transacciones que son ventas ($t.declined = '0'$), que tengan un importe entre 100 y 200 ($SAFE_CAST(t.amount AS NUMERIC) BETWEEN 100 AND 200$), y cuya fecha esté sea igual a '2015-04-29', '2018-07-20', o '2024-03-13'. Esta consulta nos devuelve solo 19 registros.

Nivell 2: Neteja i Transformació (ELT)

Escenari:

Les dades brutes tenen problemes de qualitat (símbols de moneda, usuaris duplicats, dates incorrectes). Actua com a Data Engineer per netejar-ho tot.

Exercici 1: Neteja de Productes (Data Quality)


Crearem la capa neta ("Silver") per als productes. Tens la taula `sprint3_bronze.products_raw` carregada des del CSV. L'equip de Data Governance et demana crear una taula de productes neta a `sprint3_silver.products_clean` que compleixi aquestes regles de qualitat:

» **Estandardització de Noms:** La columna original `id` és ambigua; reanomena-la a `product_id`. La columna `product_name` simplifica-la a `name`.

» **Neteja d'IDs:** El camp `warehouse_id` té el format antic "WH-4". Elimina el prefix "WH-" i converteix el valor a número enter (INT64).

» **Garantia de Preu:** Assegura't que `price` és un número (FLOAT64), sense símbols de moneda.

» **Altres columnes:** Conserva el camp `weight` (pes) tal qual.



```
1 CREATE OR REPLACE TABLE `sprint3-analytics-jordi-m.sprint3_silver.products_clean` AS
2 SELECT
3   CAST(id AS INT64) AS product_id,
4   product_name AS name,
5   CAST(
6     TRIM(TRANSLATE(CAST(price AS STRING), '$€£', '')) AS NUMERIC
7   ) AS price,
8   colour,
9   CAST(weight AS FLOAT64) AS weight,
10  SAFE_CAST(REGEXP_EXTRACT(warehouse_id, r'(\d+)') AS INT64) AS warehouse_id
11 FROM `sprint3-analytics-jordi-m.sprint3_bronze.products_raw`;
```

Query completed

Using on-demand processing quota

Query results

Job information Results Execution details Execution graph

This statement replaced the table named products_clean. Go to table

Creamos (o reemplazamos si ya existe) la tabla 'products_clean' en base a la tabla 'products_raw', cambiando el nombre de la columna `id` por `product_id` para evitar ambigüedad y lo pasamos a INT64, ya que los valores de `id` son puramente numéricos, y de esta manera será más eficiente trabajar con ellos si hacemos JOINS, por ejemplo. También cambiamos el nombre de `product_name` a simplemente `name`. Aplicamos las funciones `TRIM()` y `TRANSLATE()` a la columna `price` para deshacernos de posibles espacios y símbolos monetarios que podrían crear errores al aplicar `SAFE_CAST()` y transformarla a `NUMERIC`. Como explicamos anteriormente, `NUMERIC` genera menos errores al transformar valores alfanuméricos a números con decimales, lo cual podría tener un alto

impacto en el negocio si la transformación se hiciera mal. La columna weight la transformamos a FLOAT, y la columna colour la dejamos tal y como estaba. Finalmente aplicamos una función REGEXP_EXTRACT() a la columna warehouse_id para que extraiga sólo los dígitos que encuentre en la misma, y los transformamos a INT64.

Exercici 2: Creació de Transaccions Netes (Capa Silver)

Escenari:

La taula transactions_raw (Bronze) és insegura: l'import (amount) podria tenir lletres, les coordenades podrien fallar i la data és un text difícil de filtrar. Crearem la taula definitiva sprint3_silver.transactions_clean que garanteixi el següent.

- » **Estandardització de Noms:** La columna original id és ambigua; reanomena-la a transaction_id.
- » **Robustesa en Imports:** Utilitza SAFE_CAST al camp amount. Si falla, substitueix-lo per 0 (usant IFNULL).
- » **Dates Reals:** Converteix el camp timestamp (que és STRING) a tipus TIMESTAMP real.
- » **Coordenades:** Assegura que lat i longitude siguin FLOAT64 (utilitza SAFE_CAST per seguretat).
- » **Desglose de Productos:** Transforma la cadena de texto **product_ids** en un **ARRAY de enteros**.
 - *Input:* "1, 2, 3" (String)
 - *Output:* [1, 2, 3] (Array/Lista de enteros)
- » **Resta de camps:** Mantén-los igual.

```
1 CREATE OR REPLACE TABLE `sprint3-analytics-jordi-m.sprint3_silver.transactions_clean` AS
2 SELECT
3   id AS transaction_id,
4   card_id,
5   business_id,
6   PARSE_TIMESTAMP('%Y-%m-%d %H:%M:%S', timestamp) AS timestamp,
7   IFNULL(SAFE_CAST(amount AS NUMERIC), 0) AS amount,
8   SAFE_CAST(declined AS INT64) AS declined,
9   ARRAY (
10     SELECT SAFE_CAST(product_id AS INT64)
11     FROM UNNEST(SPLIT(product_ids, ',')) AS product_id
12   ) AS product_ids,
13   CAST(user_id AS INT64) AS user_id,
14   SAFE_CAST(lat AS FLOAT64) AS lat,
15   SAFE_CAST(longitude AS FLOAT64) AS longitude
16 FROM `sprint3-analytics-jordi-m.sprint3_bronze.transactions_raw`;
```

Query completed

Query results

Job information Results Execution details Execution graph

This statement replaced the table named transactions_clean. Go to table

Creemos (o reemplazamos si ya existe) la tabla 'transactions_clean' en base a la tabla 'transactions_raw', cambiando el nombre de la columna id por transaction_id para evitar ambigüedad. Aplicamos una función PARSE_TIMESTAMP() a la columna timestamp con el formato pertinente para extraer bien la fecha y hora en formato timestamp y así poder hacer operaciones con ella más fácilmente. Importamos de manera robusta la columna amount con un SAFE_CAST(), y en caso de que nos devuelva un valor nulo, éste se sustituirá por '0'. También lo convertimos a valor NUMERIC, como ya explicamos anteriormente. Las columnas declined y user_id las convertimos a INT64, ya que de esta manera SQL podrá operar mejor con ellas si aplicamos filtros. También extraemos en forma de array la información de product_ids, desanidándola, y convirtiéndola en el proceso en un INT64 . Finalmente convertimos a FLOAT64 las columnas lat y longitude.


Exercici 3: Unificació d'Usuaris (UNION)

Tenim els usuaris fragmentats per regió.

Tasca:

Crea la taula sprint3_silver.users_combined. Utilitza UNION ALL per unificar els usuaris dels EUA i Europa en una única llista mestra. Afegeix una columna calculada origin per saber d'on venen.

» **Estandardització de Noms:** La columna original id és ambigua; reanomena-la a user_id.



```
1 CREATE OR REPLACE TABLE 'sprint3-analytics-jordi-m.sprint3_silver.users_combined' AS
2 SELECT
3   CAST(id AS INT64) AS user_id,
4   name,
5   surname,
6   phone,
7   email,
8   birth_date,
9   'Europe' AS origin,
10  country,
11  city,
12  postal_code,
13  address
14 FROM 'sprint3-analytics-jordi-m.sprint3-bronze.european_users_raw'
15 UNION ALL
16 SELECT
17   CAST(id AS INT64) AS user_id,
18   name,
19   surname,
20   phone,
21   email,
22   birth_date,
23   'America' AS origin,
24   country,
25   city,
26   postal_code,
27   address
28 FROM 'sprint3-analytics-jordi-m.sprint3-bronze.american_users_raw';
```

Query completed

Query results

Job information Results Execution details Execution graph

This statement created a new table named users_combined. Go to table

Creemos (o reemplazamos si ya existe) la tabla 'users_combined' en base a las tablas 'european_users_raw' y 'american_users_raw'. Combinaremos ambas tablas con un UNION ALL para que incluya posibles valores duplicados. Además, cambiaremos el nombre de la columna id por user_id, y la transformaremos a un valor INT64 en ambas tablas para

mantener la coherencia con la tabla 'transactions_clean'. Finalmente, añadiremos una columna origin, que en el caso de los usuarios que vienen de 'european_users_raw' se rellenará con el valor 'Europe', y los que vengan de 'american_users_raw' con el valor 'America', para que no sea fácil identificar el continente de origen de cada transacción. Esto podrá ayudarnos a ver en qué continente se generan mayores beneficios, u otros patrones. El resto de columnas las mantenemos como estaban.

Exercici 4: Materialització de Companyies i Targetes de Crèdit


Escenari:

Per completar el model de dades a la capa Silver, ens falten dues dimensions clau que actualment depenen de fitxers CSV externs: **Companyies** i **Targetes de Crèdit**. No podem dependre de fitxers solts per a l'anàlisi final. Hem d'importar aquestes dades a taules natives (Silver) i aprofitar per corregir formats.

🧩 Tasques:

- » 1. Crea la taula `sprint3_silver.companies_clean`. Copia les dades tal qual, però assegura't que sigui una taula nativa de BigQuery (no una vista externa).
- » 2. Crea la taula `sprint3_silver.credit_cards_clean`. Copia les dades tal qual, però assegura't que sigui una taula nativa de BigQuery (no una vista externa).

Si cal, reanomenar l'id segons correspongui.



```
1 CREATE OR REPLACE TABLE `sprint3-analytics-jordi-m.sprint3_silver.companies_clean` AS
2 SELECT *
3 FROM `sprint3-analytics-jordi-m.sprint3_bronze.companies_raw`;
```

Query completed

Query results

Job information Results Execution details Execution graph

This statement created a new table named companies_clean. [Go to table](#)

Creamos (o reemplazamos si ya existe) la tabla 'companies_clean' en base a la tabla 'companies_raw' sin aplicar cambios.

```
1 CREATE OR REPLACE TABLE 'sprint3-analytics-jordi-m.sprint3_silver.credit_cards_clean' AS
2 SELECT
3   * EXCEPT(id, user_id),
4   id AS card_id,
5   CAST(user_id AS INT64) AS user_id
6 FROM 'sprint3-analytics-jordi-m.sprint3_bronze.credit_cards_raw';
```


Query completed

Query results

Job information Results Execution details Execution graph

This statement created a new table named credit_cards_clean. [Go to table](#)

Creamos (o reemplazamos si ya existe) la tabla 'credit_cards_clean' en base a la tabla 'credit_cards_raw', cambiando con una función EXCEPT() únicamente el nombre de la columna id por card_id, y transformando user_id a INT64 para mantener la coherencia con las otras tablas.



The screenshot shows the Databricks interface with the 'sprint3_silver' dataset selected. The 'Tables' tab is active, displaying a list of tables. The 'credit_cards_clean' table is highlighted with an orange box.

Table ID	Type	Create time	Expiry time	Label
companies_clean	Table	5 Jun 2026, 19:07:03 UTC+2	4 Aug 2026, 19:07:03 UTC+2	None
credit_cards_clean	Table	5 Jun 2026, 19:13:48 UTC+2	4 Aug 2026, 19:13:48 UTC+2	None
products_clean	Table	5 Jun 2026, 18:55:31 UTC+2	4 Aug 2026, 18:55:31 UTC+2	None
transactions_clean	Table	5 Jun 2026, 19:02:32 UTC+2	4 Aug 2026, 19:02:32 UTC+2	None
users_combined	Table	5 Jun 2026, 19:03:58 UTC+2	4 Aug 2026, 19:03:58 UTC+2	None

Analizando el dataset 'sprint3_silver', las tablas quedarían de esta manera.

Nivell 3: Presentació de Dades i Creació de Vistes

Exercici 1: La Vista de Màrqueting (Lògica de Negoci)

Màrqueting necessita segmentar els clients corporatius, però no saben fer JOINS. La teva tasca és deixar-los la informació preparada.

Tasca:

Crea una vista anomenada `sprint3_gold.v_marketing_kpis` que mostri la següent informació per a cada companyia:

» **Nom de la companyia, Telèfon i País** (origen: `companies_clean`).


» **Mitjana de compra** (`AVG(amount)` de `transactions_clean`).

» **Classificació de Client (Lògica):**

- Crea una columna calculada anomenada `client_tier`.
- Si la mitjana de compra és superior a **260€**, etiqueta com a **"Premium"**.
- Si és igual o inferior, etiqueta com a **"Standard"**.

Entrega:

Realitza una consulta `SELECT *` sobre la teva nova vista, ordenant els resultats perquè apareguin primer els clients "Premium" i, dins d'aquests, els que tinguin major mitjana de compra.



```
1 CREATE OR REPLACE VIEW `sprint3-analytics-jordi-m.sprint3_gold.v_marketing_kpis` AS
2 SELECT
3   c.company_name,
4   c.phone,
5   c.country,
6   ROUND(AVG(t.amount), 2) AS media_total,
7   CASE
8     WHEN AVG(t.amount) > 260 THEN 'Premium'
9     ELSE 'Standard'
10  END AS client_tier
11 FROM `sprint3-analytics-jordi-m.sprint3_silver.companies_clean` AS c
12 JOIN `sprint3-analytics-jordi-m.sprint3_silver.transactions_clean` AS t
13   ON c.company_id = t.business_id
14 WHERE t.declined = 0
15 GROUP BY
16   c.company_id,
17   c.company_name,
18   c.phone,
19   c.country;
```

Creemos la vista con esta consulta. Agruparemos los valores por `company_id` además del resto de valores para evitar, por ejemplo, que dos compañías que son diferentes pero comparten el mismo nombre se agrupen juntas.

QUntitled queryRunSaveDownloadShareScheduleOpen inMore

```
1 SELECT *
2 FROM `sprint3-analytics-jordi-m.sprint3_gold.v_marketing_kpis`
3 ORDER BY media_total DESC;
```

Query completed
Using on-demand processing quota

>|Query resultsChatView all jobsSave resultsOpen in

Job information	Results	Visualisation	JSON	Execution details	Execution graph
Row	company_name	phone	country	media_total	client_tier
1	Ac Fermentum Incorporated	06 85 56 52 33	Germany	284.91	Premium
2	Pretium Neque Corp.	07 77 48 55 28	Australia	275.58	Premium
3	Urna Convallis Associates	06 01 24 77 04	United States	273.57	Premium
4	At Associates	09 56 61 10 65	New Zealand	272.74	Premium
5	Metus Vitae Associates	08 25 44 40 66	Australia	270.05	Premium
6	Aliquet Diam Limited	02 76 61 47 46	United States	269.29	Premium
7	Nec Luctus LLC	02 14 71 75 73	Norway	268.6	Premium
8	Neque Tellus Incorporated	04 43 18 34 19	Ireland	267.56	Premium
9	Cras Consulting	07 50 10 85 63	Belgium	267.38	Premium
10	Sed LLC	01 63 16 26 52	Belgium	266.61	Premium
11	Eget Ipsum Ltd	03 67 44 56 72	United States	266.27	Premium
12	Tortor Nunc Commodore Company	05 35 92 77 16	United States	266.26	Premium
13	Amet Institute	06 33 40 21 33	Australia	265.54	Premium
14	Fusce Corp.	08 14 97 58 85	United States	265.12	Premium
15	Ut Semper Foundation	01 60 36 33 06	Sweden	264.73	Premium

Results per page: 501 - 50 of 100|<<>>|

Resultados de la vista creada, ordenada para que aparezcan primero los usuarios 'Premium' y después los 'Standard', y por cada categoría, ordenado de mayor a menor según la media_total. La consulta a la vista nos devuelve 100 valores, y la categorización de clientes nos puede ayudar a crear y dirigir mejores campañas de marketing.


Exercici 2: Rànquing de Productes (La Potència dels Arrays)

Escenari de Negoci:

L'equip de vendes vol optimitzar el catàleg. Necessiten un informe a la capa Gold que mostri el rendiment real de cada producte. Gràcies a la teva bona enginyeria a la capa Silver, la taula `transactions_clean` ja té els IDs de producte perfectament organitzats en una llista (Array). Ara toca explotar aquesta estructura.

Requisits de l'Informe:

- » **Detall del Producte:** Ha d'incloure `product_id`, `name`, `price` i `colour` (vénen de la taula `products_clean`).
- » **Mètrica de Negoci:** Una columna nova `total_sold` que compti quantes vegades apareix aquest producte a les transaccions.
- » **Integritat:** Han d'aparèixer tots els productes, fins i tot els que tenen 0 vendes (potser cal descatalogar-los).



```
1 CREATE OR REPLACE TABLE 'sprint3-analytics-jordi-m.sprint3_gold.product_sales_ranking' AS
2 SELECT
3   p.product_id,
4   p.name,
5   p.price,
6   p.colour,
7   COUNT(t.product_ids) AS total_sold
8
9 FROM 'sprint3-analytics-jordi-m.sprint3_silver.products_clean' AS p
10 LEFT JOIN 'sprint3-analytics-jordi-m.sprint3_silver.transactions_clean' AS t
11   ON p.product_id IN UNNEST(t.product_ids)
12   AND t.declined = 0
13 GROUP BY p.product_id, p.name, p.price, p.colour
14 ORDER BY total_sold DESC;
```

Query completed
Using on-demand processing quota

Query results

Job information Results Execution details Execution graph

This statement created a new table named product_sales_ranking. [Go to table](#)

Creemos o reemplazamos la tabla cogiendo los `product_id`, `name`, `price`, `colour`, y `total_sold`. Con un `LEFT JOIN` de la tabla `products_clean` hacia la tabla `transactions_clean` para no omitir ningún valor de la tabla `products_clean`. Desanidaremos los valores de `product_ids` para poder contarlos y ver cuánto se vendió cada producto, por lo cual aplicaremos el filtro `declined = 0`.

QUntitled queryRunSaveDownloadShareScheduleOpen inMore

```
1 SELECT *
2 FROM 'sprint3-analytics-jordi-m.sprint3_gold.product_sales_ranking';
```

Query completed
Using on-demand processing quota

Query resultsChatView all jobsSave resultsOpen in


Job information	Results	Visualisation	JSON	Execution details	Execution graph
Row	product_id	name	price	colour	total_sold
1	52	riverlands the duel	31.52	#727272	2642
2	29	Tully maester Tully	167.2	#111111	2627
3	21	duel Direwolf	96.9	#e2e2e2	2603
4	16	the duel warden	180.91	#666666	2602
5	33	duel warden	127.09	#191919	2593
6	87	sith Jade	96.26	#e2e2e2	2591
7	66	mustafar jinn	2.12	#545454	2590
8	48	rock Renly in	21.53	#9e9e9e	2589
9	68	Stark Karstark	167.37	#333333	2587
10	23	riverlands north	169.96	#545454	2586
11	88	Stannis warden south	167.15	#515151	2582
12	73	Dorne bastard	114.09	#848484	2579
13	34	of north	128.48	#919191	2574
14	31	Lannister	85.02	#3f3f3f	2573
15	4	warden south duel	71.89	#111111	2573

Results per page: 501 - 50 of 100

Hacemos una consulta a la tabla creada para ver los resultados.


Exercici 3: Exportació de Resultats

El teu mànager no té accés a BigQuery i vol el llistat de "Top Productes" en un Excel per a una reunió.



The screenshot shows the Google BigQuery interface. At the top, there's a "Query editor" with a query: `SELECT * FROM `sprint3-analytics-jordi-w.sprint3_gold.product_sales_ranking`;`. Below the editor, the "Query results" section is visible, showing a table with 15 rows and 7 columns: `product_id`, `name`, `price`, `colour`, `total_sold`, and `total_sold`. The table contains data for various products like "riverlands the duel", "Tully maester Tully", etc. In the top right corner of the "Query results" section, the "Save results" button is highlighted with a red box.

Podemos descargar los resultados de la tabla haciendo una consulta de todo, y buscando el botón Save results.



This screenshot shows the same BigQuery interface as the previous one, but with the "Save results" dropdown menu open. The menu offers several options for saving the query results: "Copy to Clipboard up to 1 MB", "Google Drive CSV up to 1 GB", "JSONL (newline delimited) up to 1 GB", "Google Sheets up to 10 MB", "Local download CSV up to 10 MB", "JSON up to 10 MB", "Google Cloud Cloud Storage", and "BigQuery table". The "Local download CSV up to 10 MB" option is highlighted with a red box.

Se abrirá un desplegable con diferentes opciones, en función de si queremos guardarlo como CSV en Google Drive o en Local. Seleccionaremos una opción u otra dependiendo de nuestra necesidad y de cuan grande sea el archivo.

product_sales_ranking																
Archivo Editar Ver Insertar Formato Datos Herramientas Extensiones Ayuda																
Q Menús 100% Predet... 10 B I A																
A1	product_id															
1	product_id	name	price	colour	total_sold											
2	52	riverlands the d	31.52	#727272	2642											
3	29	Tully maester Ta	167.2	#111111	2627											
4	21	duel Direwolf	96.9	#e2e2e2	2603											
5	16	the duel warden	180.91	#666666	2602											
6	33	duel warden	127.09	#191919	2593											
7	87	sith Jade	96.26	#e2e2e2	2591											
8	66	mustafar jinn	2.12	#545454	2590											
9	48	rock Renly in	21.53	#9e9e9e	2589											
10	68	Stark Karstark	167.37	#333333	2587											
11	23	riverlands north	169.96	#545454	2586											
12	88	Stannis warden	167.15	#515151	2582											
13	73	Dorne bastard	114.09	#949494	2579											
14	34	of north	128.48	#919191	2574											
15	31	Lannister	85.02	#3f3f3f	2573											
16	4	warden south du	71.89	#111111	2573											
17	54	dooku solo	13.14	#e5e5e5	2572											
18	28	chewbacca mus	127.44	#efefef	2572											
19	38	ewok sith	55.43	#666666	2571											
20	39	warden	196.65	#a0a0a0	2570											
21	36	Lannister	96.22	#a5a5a5	2570											
22	61	Winterfell Lannis	28.01	#848484	2568											
23	72	north	161.6	#474747	2568											
24	47	Tully	82.15	#919191	2568											
25	74	duel warden	158.29	#707070	2565											
26	24	south duel tour	48.98	#aaaaaa	2564											
27	58	solo palpatine ct	130.59	#2b2b2b	2563											
28	2	Tarly Stark	9.24	#919191	2562											
29	64	Direwolf	195.62	#b7b7b7	2562											
30	10	Karstark Dome	119.52	#4f4f4f	2561											
31	65	riverlands the	121.91	#8b8b8b	2561											

Finalmente accedemos al archivo para ver que todo esté en orden y listo para compartir con el equipo.