

Sprint 5 — MongoDB Analytics para Plataforma Cinematográfica

Contexto General

Una plataforma de entretenimiento cinematográfico almacena información de usuarios, películas, comentarios, sesiones y cines utilizando MongoDB como base de datos NoSQL.

El objetivo de este proyecto consistió en validar la capacidad de análisis sobre datos semiestructurados, trabajando con documentos anidados, arrays y consultas de agregación propias de MongoDB para responder preguntas de negocio y operativas.

Caso 1 — Exploración Inicial y Auditoría de la Plataforma

Situación

Antes de realizar análisis avanzados, era necesario comprender el estado actual de la plataforma y validar la calidad de los datos almacenados.

Objetivos

- Obtener una muestra de comentarios registrados.
- Conocer el volumen de usuarios activos.
- Identificar la presencia geográfica de los cines.
- Determinar el primer usuario registrado.
- Cuantificar el catálogo de películas de comedia.

```

>_MONGOSH
> use sprint5_db
< switched to db sprint5_db
> db["comments"].find({}).limit(2)
< {
  _id: ObjectId('5a9427648b0beebe69579cc'),
  name: 'Andrea Le',
  email: 'andrea_le@fakegmail.com',
  movie_id: ObjectId('573a1390f29313caabcd418c'),
  text: 'Rem officis eaque repellendus amet eos doloribus. Porro dolor voluptatum voluptates neque culpa molestias. Voluptate unde nulla temporibus
  date: 2012-03-26T23:20:16.000Z
}
{
  _id: ObjectId('5a9427648b0beebe69579cf'),
  name: 'Greg Powell',
  email: 'greg_powell@fakegmail.com',
  movie_id: ObjectId('573a1390f29313caabcd41b1'),
  text: 'Tenetur dolorum molestiae ea. Eligendi praesentium unde quod porro. Commodi nisi sit placeat rerum vero cupiditate neque. Dolorum nihil ver
  date: 1987-02-10T00:29:36.000Z
}
sprint5_db>

```

Con esta simple consulta (remarcada en naranja) extraemos los primeros dos comentarios (remarcados en rojo) y la información que tenemos sobre ellos.

```

>_MONGOSH
> use sprint5_db
< switched to db sprint5_db
> db["users"].countDocuments()
< 185
sprint5_db> |

```

Para saber cuántos usuarios tenemos en nuestra base de datos aplicamos la función countDocuments(). Tenemos registrados 185 usuarios.

```

>_MONGOSH
> use sprint5_db
< switched to db sprint5_db
> db.theaters.countDocuments({
  "location.address.state": "CA"
})
< 169
sprint5_db> |

```

Queremos saber cuántos cines hay en el estado de California. Con esta consulta descubrimos que hay 169.

```
>_MONGOSH
> use sprint5_db
< switched to db sprint5_db
> db["users"].findOne()
< {
  _id: ObjectId('59b99db4cfa9a34dcd7885b6'),
  name: 'Ned Stark',
  email: 'sean_bean@gameofthron.es',
  password: '$2b$12$UREFwsRUoyF0CRqGNK0Lz00HM/jLhgUCNNIJ9RJAqMUQ74cr1J1Vu'
}
sprint5_db> |
```

El equipo quiere conocer la información de nuestro primer usuario. Utilizamos la función `findOne()` para ello, y nos aparece por pantalla la información del mismo.

```
>_MONGOSH
> use sprint5_db
< switched to db sprint5_db
> db.movies.countDocuments({
  type: "movie",
  genres: "Comedy"
})
< 7002
sprint5_db>
```

El equipo quiere saber cuántas películas catalogadas de comedia tenemos en la base de datos. Aplicamos los filtros correspondientes y vemos que en total tenemos 7002.

Caso 2 — Segmentación del Catálogo Cinematográfico

Situación

El departamento de contenidos necesitaba localizar películas históricas que cumplieran determinadas características narrativas y lingüísticas para futuras campañas temáticas.

Objetivo

Identificar todas las películas producidas en 1932 que:

- pertenecieran al género Drama,
- o estuvieran disponibles en francés.

The screenshot shows the MongoDB Compass interface. On the left, the 'CONNECTIONS' panel lists 'localhost:27017' with databases 'admin', 'config', 'local', and 'sprint5_db'. The 'sprint5_db' database is selected, showing collections 'comments', 'movies', 'sessions', 'theaters', and 'users'. The 'movies' collection is open, displaying 24K documents. A query is entered in the search bar: `{type: "movie", year: 1932, $or: [{genres: "Drama"}, {languages: "French"}]}`. The results show two documents. The first document is for 'The Blood of a Poet' (1932), a Drama in French, released on 2010-05-20. The second document is for 'The Blue Light' (1932), a Drama in French, released on 1934-05-08. Both documents include fields for _id, plot, runtime, poster, title, lastupdated, languages, released, directors, writers, awards, imdb, countries, type, and tomatos.

Desde la interfaz, aplicamos la función de búsqueda con filtros OR para quedarnos con películas hechas en 1932, que sean del género Drama, o que estén disponibles en Francés. Vemos en la parte superior derecha que la consulta nos devuelve 18 resultados, y en la parte central veríamos toda la información de las películas que cumplen con los criterios.

Caso 3 — Análisis de Películas Premiadas Recientes


Situación

La dirección de contenidos solicitó identificar producciones estadounidenses de alto rendimiento para estudiar patrones de éxito comercial y crítico.

Objetivo

Localizar películas:

- producidas entre 2012 y 2014,
- con entre 5 y 9 premios ganados,
- pertenecientes al mercado estadounidense.



The screenshot shows the MongoDB Compass interface. On the left, the 'Connections' panel lists 'localhost:27017' with a tree view of databases including 'sprint5_db'. The main panel displays the 'movies' collection in 'sprint5_db'. A query is entered in the search bar: `{type:'movie',year:{$gte:2012,$lte:2014},'awards.wins':{$gte:5,$lte:9},countries:'USA'}`. Below the query, two document results are shown. The first document is for 'The Secret Life of Walter Mitty' (2013), and the second is for 'The Croods' (2013). Both documents show a 'wins' field with a value of 5, indicating they match the criteria.

Para filtrar por un intervalo de valores, tendremos que utilizar operadores como “mayor que (\$gte)” y “menor que (\$lte)”. Aplicándolos a las variables que nos pide el equipo, descubrimos que tenemos 162 resultados que cumplan con estos criterios.

Caso 4 — Participación de Usuarios por Dominio Corporativo

Situación

El equipo de marketing quería analizar el nivel de participación de usuarios vinculados a un dominio concreto.

Objetivo

Calcular cuántos comentarios había realizado cada usuario con correo perteneciente al dominio “gameofthron.es”.

```
>_MONGOSH
> use sprint5_db
< switched to db sprint5 db
> db.comments.aggregate([
  {
    $match: {
      email: /.*gameofthron.es.*/
    }
  },
  {
    $group: {
      _id: null,
      total_comentarios: {
        $sum: 1
      }
    }
  }
])
< {
  _id: null,
  total_comentarios: 22841
}
sprint5_db> |
```

Para encontrar la solución, tendremos que usar funciones de agregación, como son por ejemplo \$match para filtrar a través de una expresión regular, y después agrupar los valores que cumplen con la expresión. Tras aplicar la consulta, vemos que los usuarios del dominio solicitados han escrito 22841 comentarios en total.

Caso 5 — Distribución Geográfica de Cines en Washington D.C.

Situación

La empresa quería conocer la distribución de sus salas de cine dentro de la capital estadounidense.

Objetivo

Determinar cuántos cines existían en cada código postal del estado de Washington D.C.


```

>_MONGOSH

> use sprint5_db
< switched to db sprint5_db
> db.theaters.aggregate([
  {
    $match: {
      "location.address.state": "DC"
    }
  },
  {
    $group: {
      _id: "$location.address.zipcode",
      contador: {
        $sum: 1
      }
    }
  }
])
< {
  _id: '20016',
  contador: 1
}
{
  _id: '20010',
  contador: 1
}
{
  _id: '20002',
  contador: 1
}
sprint5_db>

```

Para saber cuántos cines hay en el estado de Washington D.C. tendremos primero que filtrar aquellos resultados que estén en el estado de DC, para después agruparlos por su código postal. La consulta nos devuelve tres códigos postales, cada uno de ellos con sólo un cine.

Caso 6 — Identificación de Películas de Alta Valoración

Situación

El departamento editorial quería destacar títulos dirigidos por cineastas reconocidos con una valoración elevada por parte de la audiencia.

Objetivo

Encontrar todas las películas dirigidas por John Landis con una puntuación IMDb comprendida entre 7,5 y 8 puntos.

The screenshot shows the MongoDB Aggregations Builder interface. The top navigation bar includes tabs for 'sprint5_db', 'users', 'theaters', 'sessions', 'movies' (highlighted), and 'comments'. The main header shows 'localhost:27017 > sprint5_db > movies' and a button to 'Open MongoDB shell'. Below the header, there are tabs for 'Documents (24K)', 'Aggregations' (highlighted), 'Schema', 'Indexes (1)', and 'Validation'. The 'Aggregations' tab is active, showing a pipeline with two stages. Stage 1 is named '\$match' and contains a query:

```
{ directors: "John Landis" }
```

. Stage 2 is also named '\$match' and contains a query:

```
{ "imdb.rating": { $gte: 7.5, $lte: 8 } }
```

. The output preview for Stage 1 shows a sample of 10 documents. The output preview for Stage 2 shows a sample of 4 documents, which are highlighted with red boxes. The documents in the final output are: 1. 'Faber College has one frat house so disreputable it will take anyone. ...', 2. 'Jake Blues, just out from prison, puts together his old band to save t...', 3. 'Two American college students are on a walking tour of Br and are...', and 4. 'Two American college students walking tour of Britain are att'.

Aplicando los filtros que nos pide el equipo, vemos a través de la consulta en la interfaz que hay cuatro películas que encajan dentro de los filtros.